

Documentation de la qualité des données

1. Présentation du jeu de données

Le jeu de données contient **2 060 annonces immobilières** réparties sur **16 colonnes** décrivant les caractéristiques des biens immobiliers (type de bien, localisation, superficie, nombre de pièces, prix, année de construction, etc.).

Structure du dataset

Indicateur	Valeur
Nombre de lignes	2060
Nombre de colonnes	16
Colonnes numériques	6
Colonnes textuelles	10
Taille mémoire	257.6 KB

2. Analyse des valeurs manquantes

L'analyse a permis d'identifier plusieurs colonnes contenant des valeurs manquantes.

Colonne	Valeurs manquantes	Pourcentage
country	243	11.80 %
neighborhood	250	12.14 %
surface_m2	182	8.83 %
num_rooms	128	6.21 %
num_bathrooms	113	5.49 %
floor	116	5.63 %
year_built	187	9.08 %
condition	411	19.95 %
heating_type	247	11.99 %
parking	254	12.33 %
energy_rating	220	10.68 %

Les colonnes suivantes ne présentent **aucune valeur manquante** :

- listing_id
- property_type
- city
- price

- listing_date

3. Impact des valeurs manquantes

Les valeurs manquantes peuvent avoir plusieurs conséquences :

- Réduction de la qualité des analyses statistiques.
- Baisse des performances des modèles de Machine Learning.
- Création de biais dans les visualisations Power BI.
- Difficulté à réaliser des comparaisons entre les biens.

La colonne **condition** est la plus impactée avec près de **20 %** de données absentes.

4. Traitement recommandé des valeurs manquantes

Type de colonne	Méthode recommandée
Colonnes numériques (surface_m2, num_rooms, num_bathrooms, floor, year_built)	Remplacement par la médiane
Colonnes catégorielles (country, neighborhood, condition, heating_type, parking, energy_rating)	Remplacement par la valeur la plus fréquente (mode) ou création de la catégorie "Unknown"

5. Analyse des doublons

L'analyse du dataset montre la présence de :

Nombre de lignes dupliquées : 60

6. Impact des doublons

La présence de doublons peut entraîner :

- Une surestimation du nombre de biens immobiliers.
- Une distorsion des statistiques descriptives.
- Des erreurs dans les indicateurs Power BI.

- Des biais dans les modèles de Machine Learning.

7. Traitement des doublons

Le traitement recommandé consiste à :

- Identifier les lignes totalement identiques.
- Supprimer les doublons complets.
- Vérifier les doublons métier (même bien immobilier enregistré plusieurs fois avec le même `listing_id`).

Après suppression :

- Nombre initial de lignes : **2060**
 - Doublons supprimés : **60**
 - Nombre final de lignes : **2000**
-

8. Analyse des valeurs aberrantes

Une analyse de l'asymétrie (Skewness) des variables numériques a été réalisée afin d'identifier la présence éventuelle de valeurs aberrantes.

Résultats obtenus

Variable	Skewness	Interprétation
price	0.0059	Distribution quasiment symétrique
surface_m2	6.6624	Très forte asymétrie positive

Analyse

La variable **price** présente une valeur de skewness très proche de zéro (**0,0059**), indiquant une distribution presque parfaitement symétrique. Les prix sont répartis de manière équilibrée autour de la moyenne et aucune présence importante de valeurs aberrantes n'est suggérée.

En revanche, la variable **surface_m2** présente une skewness de **6,6624**, ce qui révèle une très forte asymétrie positive. Cette distribution indique que la majorité des biens possède une surface faible ou moyenne, tandis qu'un nombre réduit de biens présente des superficies exceptionnellement élevées.

Cette forte asymétrie suggère la présence probable de **valeurs aberrantes (outliers)**, correspondant à des biens atypiques ou de très grande superficie.

Impact des valeurs aberrantes

Les valeurs aberrantes peuvent avoir plusieurs conséquences :

- Influence excessive sur la moyenne et l'écart-type.
 - Biais dans les analyses statistiques.
 - Diminution des performances des modèles de Machine Learning.
 - Représentations graphiques moins fidèles à la distribution réelle des données.
-

9. Conclusion

L'analyse de la qualité des données met en évidence plusieurs points d'attention :

- **Valeurs manquantes** dans **11 colonnes**, principalement **condition (19,95 %)**, **parking (12,33 %)**, **neighborhood (12,14 %)** et **heating_type (11,99 %)**.
- **60 doublons**, représentant environ **2,91 %** du jeu de données.
- **Présence probable de valeurs aberrantes** dans la variable **surface_m2**, caractérisée par une très forte asymétrie positive (**skewness = 6,6624**). À l'inverse, la variable **price** présente une distribution quasi symétrique (**skewness = 0,0059**) et ne montre pas d'indice significatif de valeurs aberrantes.

Avant toute analyse ou modélisation, il est recommandé de :

1. Imputer les valeurs manquantes selon le type des variables (médiane pour les variables numériques, mode ou catégorie "**Unknown**" pour les variables catégorielles).
2. Supprimer les doublons afin d'obtenir un jeu de données propre et fiable.
3. Vérifier la cohérence des identifiants (`listing_id`) pour éviter les enregistrements répétés.
4. Détecter et analyser les valeurs aberrantes à l'aide de méthodes statistiques (IQR ou Boxplot) avant de décider de leur traitement.